DELIVERY ACCEPTANCE · 交付验收

企业 AI 智能体中台 · 交付链路一页纸

M0 脚手架 → M4 编排 → M5 审批 → M6 真实底座 → M7 计量闭环：每一环都有可复跑的证据，不是口头结论

链路状态 · 已闭环

7 / 7

阶段全部可运行

版本 **v0.5.0**　日期 **2026-11-02**　代码真源 **D:\enterprise-ai-platform**　远程 **hujian-ux/ruishenhang**

门禁 **GitHub Actions quality-gate**

自动化测试	前端契约	接口契约	真实底座	CI 门禁	计量落账
55 项	**33 项**	**17 paths**	**3 / 3 PASS**	**3 次全绿**	**32 单**
pytest 全绿 · 87s	真实 HTTP 链路复刻	24 schemas	PG · 对象存储 · 真 LLM	每次推送自动跑	真实 token 与成本

一、交付链路　每段的「证据」都能当场复跑，命令见文末

M0 · 已验收

脚手架 · 先单体后拆容器

FastAPI 单体 + React/Vite/TS；网关中间件注入 X-Caller-Context，前端不可伪造；docker-compose 只跑基础设施。

证据：**8 paths** 契约落地、CI 三道门禁首次全绿

M4 · 已验收

智能体编排 · 会话记忆

LangGraph 图编排 `retrieve → generate`；会话归属校验、6 轮注入 / 40 轮滑动窗口、指代消解式 query 改写。

证据：**7 项测试** + 跨智能体串记忆隔离、他人访问 403

M5 · 已验收

审批流 · 发布红线

注册自动开审批单；dept_admin 限本部门、重复决策 409；**未发布智能体调用一律 403。**

证据：**9 项测试**；契约验证「未发布 invoke 被拦」实测 403

M6 · 已验收

真实底座 · 不再是演示数据

PG 写穿（会话/审批单重启载回）、对象存储原文可回读、LiteLLM 接通义千问真生成；全部优雅降级。

证据：本机实跑 **3/3 PASS**，第三项为「真实 LLM 生成」

M7 · 已验收

计量闭环 · 会拦人的计费

每次调用落一单账（真 token / 成本 / 延迟 / 真伪生成）；五维聚合出账单；部门配额超限 **invoke 直接 429。**

证据：**9 项测试** + 契约 16 项；PG 已有真实账单行

二、实机证据　本机原生三件套（Docker 守护进程故障，改原生等价路径，接口代码零改动）



2026-11-02 18:23 本机终端实拍：PostgreSQL / 对象存储 / LiteLLM 三项 **[PASS]**，结论区 **[ALL PASS] 3/3**，生成标注「真实LLM生成」。

```
# python scripts/validate_m6.py
[PASS] PG 写穿 + 重启载回会话/审批单
       RESTART agent_sessions 载回 10 条（含目标=True）
       RESTART approval_tickets 载回 10 条（含目标=True）
[PASS] MinIO 文档原文上传 + 回读一致
       写入 minio://kb-files/val/kb_sample.txt；回读一致=是
[PASS] LiteLLM 可达 + 智能体调用
       模型=qwen-plus；真实LLM生成：[第1轮|LLM生成] 知识库
       混合检索的原理是结合关键词匹配与语义向量检索…

[ALL PASS] 三项底座全部真实生效：3/3 通过。
```

```
# node scripts/contract_check.mjs（节选）
✓ 未发布 invoke 被拦（403）
✓ 第二轮记忆改写（query_rewritten=true）
✓ token 落账：入 126 / 出 40
✓ 成本按单价折算：¥0.000181
✓ 生成方式可判别：真实 LLM
✓ 上传后立即可被召回（同一份索引）
```

三、平台能力现状　「验证方式」列写的是可复跑的动作，不是承诺

能力	实现要点	验证方式（可复跑）	状态
带权召回	混合检索（BM25 字符 bigram + 向量）+ RRF 融合 + 父子切分聚合 + 重排；第 18 章单一过滤点在召回阶段剔除越权	pytest 断言 `filtered_out ≥ 1` 且不泄漏；CI 跑 Recall@100 ≥ 0.95 门禁；契约实测「召回 6 条 / 过滤 5 条」	已验收
会话记忆	归属校验（仅本人）、跨智能体隔离、注入窗口 6 轮 / 保留 40 轮、query 改写做指代消解	M4 7 项测试；契约第二轮 `query_rewritten=true`、`turn_count=4`；会话页可视化上下文预览	已验收
审批与发布	注册即开单；平台管理员全局、部门管理员限本部门；终态 409；发布后才可调用	M5 9 项测试；契约「员工决策 403 → 管理员通过 → published → 可调用」全链路	已验收
持久化	会话 / 审批单 / 用量三张表写穿 PG；启动时 `load_from_pg` 载回；不可达静默降级为内存	子进程模拟重启后能载回目标记录；`psql` 直查 `usage_records` 有真实行	已验收
真实生成	模型网关经 LiteLLM 路由；通义千问 `qwen-plus` 国内直连；不可达回退确定性 stub 并标记	直连百炼兼容端点返回 200；验证脚本标注「真实LLM生成」；账单里 `real=true`	已验收
计量计费	token 取网关真值、成本按模型单价固化到单；dept/agent/model/user/day 五维聚合；RBAC 收敛到本人/本部门/全量	M7 9 项测试；契约 16 项；PG 实查 32 单 / 2757 入 token / ¥0.0137	已验收
知识入库	multipart 上传（txt/md/csv/json…）→ 对象存储 + 落库 + **入同一份检索索引**；删除三处同步清理	契约：上传 → 立即可被召回到同一 doc_id → 删除后不再召回；越权 scope 与超大/非法类型分别 403 / 413 / 415	已验收
模型治理	注册表带单价/能力/上下文；平台管理员可启停，网关侧即时生效，业务代码零改动	契约：员工 PATCH 403 → 管理员停用 → 默认列表不再返回 → 再启用	已验收

四、治理门禁　三道自动闸门 + 两条业务红线，越线直接失败而不是告警

GATE 01

backend-build

全量 pytest（当前 55 项）+ 应用可导入；任一失败即阻断合并。

GATE 02

rag-recall-gate

第 36 章：Recall@100 ≥ 0.95，检索质量下降不允许合入。

GATE 03

ml-objective-gate

第 37 章：客观评测门槛（不依赖 LLM-as-judge，可复现）。

RED LINE 01

未发布不可调用

第 35 章：智能体必须过评审发布，`/agent/invoke` 否则 403。

RED LINE 02

配额超限即拦截

第 25 章：部门 30 天 token 封顶，超限调用 429 —— 计费在链路上，不在报表里。

RED LINE 03

越权不进上下文

第 18 章：过滤点在召回阶段，越权片段连模型上下文都进不去。

五、已知边界与下一步　先说清楚哪里还不够，再谈规模化

边界	现状与影响
内存为主存	会话/审批/计量的主存仍在进程内，PG 是副本。单实例够用，多副本需拆 Redis/PG 主存 —— **上生产前必须做。**
对象存储替代	MinIO 官方已下架免授权 Windows 二进制，本机用 S3 兼容服务验证；`object_store.py` 接口未变，换真 MinIO/OBS 只改配置。
向量库未上	Qdrant 仍是内存索引（`ensure_qdrant_collection` 已留口），万级文档以上需切真向量库。
前端权限	目前靠接口 403 兜底，未做路由级守卫与按钮级隐藏的完整矩阵。

- **M8 试点**：选 1 个部门、1 个真实知识库（200–500 篇）跑两周，产出首次真实 Recall 与成本曲线。
- **测试扩容**：评测集从当前规模扩到 200 条，覆盖跨部门越权、长文档、多轮指代三类硬样本。
- **成本护栏**：配额从「部门月封顶」细化到「智能体日预算 + 80% 预警」，与账单页打通。
- **交付形态**：先单体容器化（Dockerfile 已备），试点稳定后再按网关/运行时/检索拆三容器。
- **协作**：远程仓库已开协作者权限，PR 走 CI 门禁 + 分支保护，`COLLAB_GUIDE.md` 可直接发给同事。

数据口径：测试数 = `backend/tests` 全量 pytest（55 项，2026-11-02 实测 87s）；契约数 = `web/scripts/contract_check.mjs` 33 项真实 HTTP 断言；接口规模 = `openapi.yaml` 17 paths / 24 schemas； 底座验证 = 本机原生 PostgreSQL 16.4 + S3 兼容服务 + LiteLLM(pip) 三件套，均在 `127.0.0.1`，非 mock； 计量样例 = PG `usage_records` 直查（32 单 / 2750 入 token / ¥0.0137），真实调用产生。

复跑命令：`cd backend && .\.venv\Scripts\python.exe -m pytest -q` | `.\.venv\Scripts\python.exe scripts\validate_m6.py` | `node web\scripts\contract_check.mjs`（后端需在 8080）。