P0 35. 模型选型决策框架

迭代目标：上线前堵住“LLM 万能”误区，让每个新需求先过选型评审。

任务	产出	工期	验收
1 决策树建模	选型决策树（输入→确定性→可解释→成本）文档	2d	评审通过
2 网关扩展	第25章网关新增 adapter_type{llm,ml_serving,rule}	3d	非LLM可注册
3 向导嵌入	“新建智能体”强制填写选型说明	2d	缺选型不可发布
4 对比看板	同任务 LLM vs ML 成本/准确率对比	2d	看板可用

- 依赖：第25章模型网关。高风险：团队习惯用LLM做一切，需培训+评审红线。

P0 36. RAG 质量工程（重点）

迭代目标：把检索质量做成可度量、可门禁的工程能力，杜绝“漏召回→幻觉”。

周	任务	产出	验收/门禁
W1	混合检索：BM25 + 向量，RRF 融合；父子文档切分；权限元数据落库	融合检索服务；切分流水线	双路召回可用
W2	重排层：Top-100 → cross-encoder → Top-K；接入第25章网关	重排服务+配置	MRR 较纯向量↑
W3	评测集：≥200 条 golden queries + 标准 doc_id；Recall@K/MRR/nDCG 脚本	评测集+自动化脚本	Recall@100≥0.95
W4	质量门禁接入 CI；质量层与第18章合规层解耦；上线报告	CI 门禁+发布	门禁阻断生效

- 依赖：第5章知识库切分/元数据、第18章过滤点。
- 关键指标：Recall@100≥0.95 才放行；质量层失败不进合规层。
- 外部依据：2025-2026 混合检索+重排工程共识。

P0 37. ML 级评测体系

迭代目标：用可靠评测替代 LLM-as-judge，给自动演化(第20章)立可信地基。

任务	产出	工期	验收
1 客观校验	格式/工具参数/检索命中/引用/越权 5 类规则校验	3d	自动化通过
2 黄金集	≥500 条多轮+边界对话标注	5d	覆盖边界
3 judge 约束	LLM-as-judge 多模型交叉+校准阈值，仅辅助	2d	不单独定生死
4 演化门禁	第20章演化建议接评测门禁	2d	不达标不灰度

- 依赖：第20章自动演化、第28章测试体系。
- 外部依据：ICLR2025+arXiv 2025/2026 LLM-as-judge 系统性偏差。