大模型接入与计量计费

25. 大模型接入与计量计费（可插拔模型 + Token 统计） P0

平台必须回答两个问题——“用哪个大模型”与“花了多少”。前者通过模型网关+适配器+注册表做成可插拔接口（新增模型=加适配器+一条配置，不改业务代码）；后者通过统一计量埋点→用量统计→计费/配额闭环，按租户/部门/用户/智能体核算成本，且不绕过第 18 章单一过滤点。

25.1 为什么可插拔

- 避免锁定：厂商与模型迭代快，业务代码不应写死某家接口
- 最优性价比：简单问答用便宜小模型、复杂推理用大模型，按任务路由降本
- 混合部署：公有 API 与私有化开源并存，敏感数据走本地模型

25.2 模型网关与适配器（复用第 4 章 One API / LiteLLM）

组成	职责	扩展方式
统一接口 ModelAdapter	声明 chat/embed/rerank 与能力(流式/上下文/模态/价格)	接口固定，长期不变
具体适配器	每个模型一个实现(OpenAI/Claude/通义/自部署开源)	新增模型只加一个适配器类
模型注册表 Registry	登记模型 ID/状态/路由权重/配额	热插拔：注册/停用不改业务
路由策略	按任务/成本/质量/可用性选模型，支持降级	策略可配置

25.3 模型接入流程（5 步）

- Step1 申请/部署：公有模型申请 Key 或自建额度；私有化完成部署与压测
- Step2 实现/选用适配器：统一 chat/embed/rerank 签名
- Step3 注册到 Registry：登记模型 ID/能力/单价/状态
- Step4 配置路由与配额：设策略与部门配额，高成本模型单独审批
- Step5 灰度上线+监控：小流量灰度，盯用量与质量后转全量

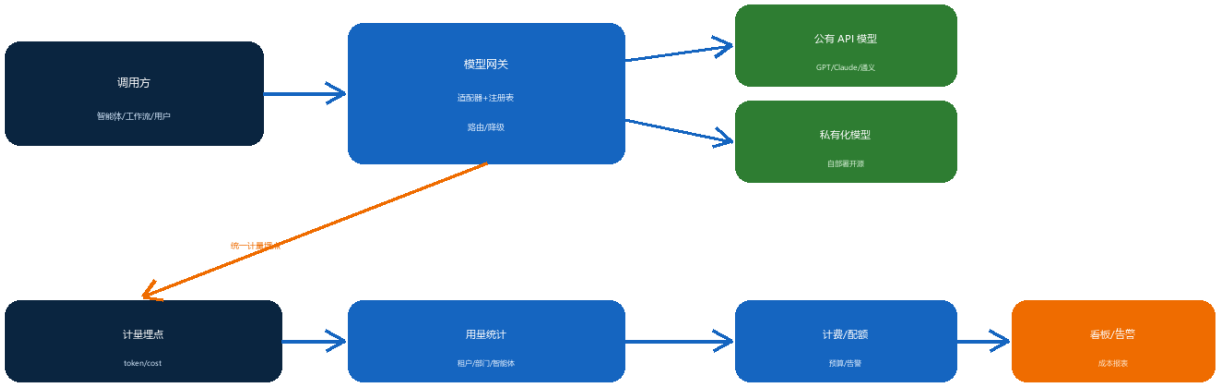
25.4 Token 用量统计（统一计量的“统计点”）

- 统一埋点：所有调用必经模型网关，按 tenant/dept/user/agent/session 采集 prompt/completion tokens 与 cost
- 与第20章演化共用采集层：一次采集同时满足演化评估与用量计费
- 成本归因：实时计数+异步落库，归因到部门、智能体、具体任务
- 用量看板：部门/个人排名、智能体消耗 Top、本月成本、剩余额度

25.5 计费与配额体系（统一管理的“计费点”）

机制	说明
配额	免费额度 / 部门月度预算 / 按量计费(内部结算或外部账单)
高成本管控	昂贵/敏感模型需审批或单独配额，避免滥用
超阈告警+熔断	接近预算告警，超限熔断或自动降级更便宜模型
内部结算报表	按成本中心出部门账单，支撑 IT 向业务分摊

25.6 计量计费架构图



▲ 图示：调用方→模型网关(适配器+注册表,热插拔)→模型集群；旁路统一计量→用量统计→计费配额→看板告警

25.7 与权限/安全衔接

用量数据同样受 scope

约束：部门只能看到本部门消耗，成本属敏感指标，跨部门汇总仅平台管理员可见；高成本/敏感模型调用仍需第 19 章 L3 人工审核。计量与计费不绕过第 18 章单一过滤点。