P0 35. 模型选型决策框架

问题(缺陷)

- 把 AI 等同 LLM+RAG，用 LLM 做确定性/批量任务→成本高数倍、不可复现、不可解释。

外部依据

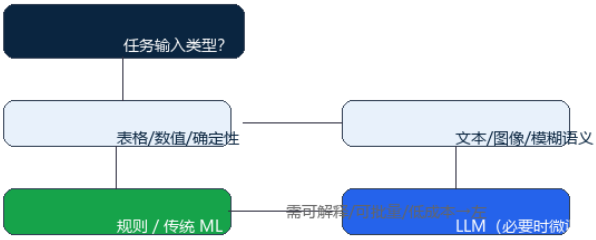
- IBM 框架：表格→传统ML；文本→LLM。LLM 批量分类成本高出数倍且非确定性。

实施步骤

- 建选型决策树(输入类型→确定性→可解释→成本)并嵌入新建智能体向导
- 第25章网关新增 adapter_type{llm,ml_serving,rule}，非LLM也走网关
- 默认策略：确定性/结构化/可批量→非LLM；仅模糊/生成/推理→LLM
- 建成本/质量对比看板，同一任务并行跑两类模型沉淀选型知识

验收清单

- 决策树上 | ≥3 传统ML/规则接入网关 | 新需求上线前过选型评审



P0 36. RAG 质量工程

问题(缺陷)

- 纯向量检索漏 30–50% 相关文档；只做权限过滤≠检索质量。

外部依据

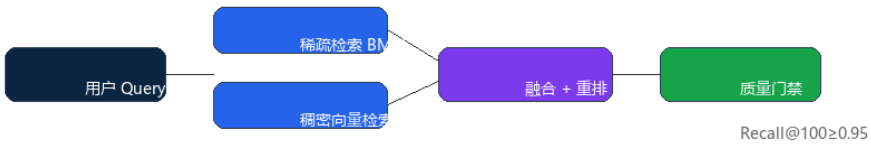
- 2025-2026 共识：混合检索+重排；先测 Recall@100≥0.95 再调生成。

实施步骤

- 混合检索：BM25 + 向量，RRF/学习排序融合
- 重排层：Top-100 用 cross-encoder 重排至 Top-K
- 语义切分+父子文档，保留来源/章节/权限元数据
- 建 ≥200 条 golden queries 评测集，CI 门禁 Recall@100<0.95 阻断
- 两层过滤：质量层(找得全) + 合规层(第18章看不见)解耦

验收清单

- 混合检索上线 | 评测集≥200条自动化 | 质量门禁 Recall@100≥0.95



P0 37. ML 级评测体系

问题(缺陷)

- 评测依赖 LLM-as-judge，人机相关性仅 0.59–0.66 会一致错，演化飞轮地基不可靠。

外部依据

- ICLR2025+arXiv 2025/2026：LLM-as-judge 有系统偏差，仅宜辅助。

实施步骤

- 客观指标用规则校验：格式/工具参数/检索命中/引用/越权拦截
- 建 ≥500 条黄金集(多轮+边界)作回归基线
- LLM-as-judge 仅辅助：多模型交叉+校准阈值，不单独定生死
- 人工抽检+用户反馈回流第20章演化
- 演化建议须过评测门禁(黄金集不退化)才灰度

验收清单

- 黄金集≥500条 | 5类客观指标自动化 | 演化接评测门禁

P1 38. 非 LLM 模型 MLOps

问题(缺陷)

- 机器学习方案只有推理调用，缺训练/特征/版本/漂移/重训。

外部依据

- 标准 MLOps：特征存储→训练流水线→注册表→漂移检测→重训。

实施步骤

- 特征存储：离线+在线统一管理，训练-serving 一致
- 训练流水线：清洗→特征→训练→评估→注册，可定时重跑
- 模型注册表与版本：与第25章网关同表(adapter=ml_serving)
- 漂移检测：PSI/KS 监控输入分布与效果衰减
- 重训与回滚：漂移触发重训，灰度+旧版可回滚

验收清单

- ≥1 传统ML走完整MLOps | 模型版本一键回滚

P1 39. 幻觉抑制与 Grounding

问题(缺陷)

- 第27章只列威胁无手段，企业最怕说错话。

外部依据

- grounding：每段附来源；无证据声明须拒答/转人工。

实施步骤

- 引用强制：每段附可点击来源，无来源不得生成事实断言
- 事实校验：生成后做声明-证据比对，证据不在检索集则标记/拒答
- 置信校准与拒答：低置信/无支撑走拒答或转人工(第42章)
- 输出合规校验层：生成后规则/小模型过滤敏感与越权

验收清单

- 关键事实100%附来源 | 人工幻觉抽检率<2%

P1 40. 成本与延迟优化

问题(缺陷)

- 第25章有计费无优化；无路由无语义缓存，规模上来成本失控。

外部依据

- 任务路由+语义缓存可降 30–60% 调用成本。

实施步骤

- 任务路由器：简单→小模型，复杂→大模型，策略可配
- 语义缓存：相似 Query 命中缓存(embedding 相似度阈值)
- 模型分层与预算：注册表标 tier/单价，高成本单独审批，超预算熔断
- 高频请求预计算，命中即返回

验收清单

- 简单任务小模型承接>40% | 语义缓存命中>20%

P1 41. 模型质量可观测性

问题(缺陷)

- 第25章只记 token/成本，不记成功率/幻觉率/转人工率。

外部依据

- 质量遥测需与可观测性打通，按维度下钻。

实施步骤

- 扩展计量埋点：成功率/幻觉率/转人工率/满意度/延迟p95
- 与第26章指标-日志-链路三支柱打通，按 tenant/dept/agent 下钻
- 质量告警：幻觉率/转人工率突增自动告警触发演化复盘
- 质量看板受 scope 约束，成本/质量仅管理员可见

验收清单

- 看板含≥5质量指标可下钻 | 超阈自动告警

P2 42. 优雅降级与人工升级

问题(缺陷)

- Agent 静默失败或硬报错，无置信阈值触发升级。

外部依据

- 置信阈值→降级链→人工升级是标配。

实施步骤

- 置信阈值：每答带置信分，低于阈值走降级链(小模型→规则→人工)
- 降级链配置：每智能体可配降级顺序与兜底话术
- 人工升级：转人工带完整上下文与置信理由，进工单/审批流

验收清单

- 每智能体配降级链 | 低置信自动转人工带上下文

P2 43. 中文语言特化

问题(缺陷)

- Embedding/LLM 需中文优化未单列，分词专名易错。

外部依据

- 中文优化 embedding + 中文基准更稳。

实施步骤

- 默认中文 embedding(bge/bce 系列)，第25章注册表可切
- 检索切分考虑中文语义边界，避免标点粗暴切
- 建中文少样本/系统 Prompt 模板库，规避翻译腔
- 用 C-Eval/CMMLU/内部中文集做回归基准

验收清单

- 中文优化 embedding 为默认 | 中文集纳入回归

P2 44. Agent/工具层安全闭环

问题(缺陷)

- 第18章过滤点只在检索层；工具调用/外部API 可绕过权限外泄。

外部依据

- 工具层须复用同一过滤器，出网脱敏。

实施步骤

- 工具调用也过权限：每工具声明 scope/数据域，调用前校验 caller
- 外部 API 沙箱与脱敏：去手机/身份证/密钥，仅白名单域名
- 工具审计：入参/出参/调用者进统一审计流(第29章)
- 复用第18章单一过滤点代码，不另起炉灶

验收清单

- 100% 工具调用经校验 | 出网经脱敏网关白名单