P0 35. 模型选型决策框架

缺陷：把 AI 等同 LLM+RAG，用 LLM 做确定性/批量任务→成本高数倍、不可复现、不可解释。

- 建选型决策树（输入类型→确定性→可解释→成本），嵌入“新建智能体”向导并强制填写选型说明。
- 第25章网关新增 adapter_type{llm, ml_serving, rule}，传统ML/规则也走同一网关，统一 caller 注入与计量。
- 默认策略：确定性/结构化/可批量→非LLM；仅模糊/生成/推理→LLM；关键决策引入LLM须人机共签（第33章）。
- 建成本/质量对比看板，同一任务并行跑两类模型沉淀选型知识库。

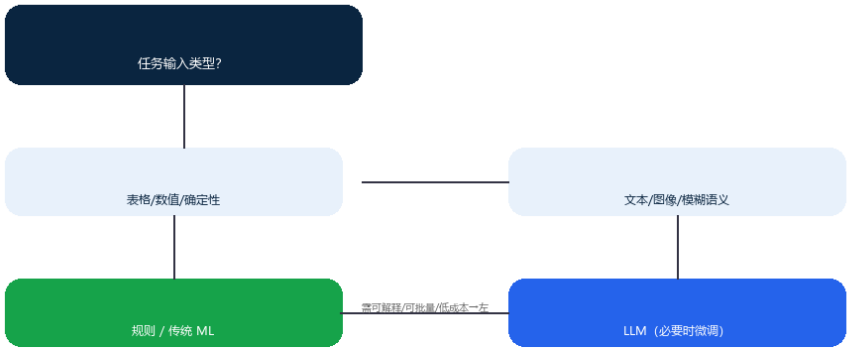


图 35.2 选型决策树

P0 36. RAG 质量工程

缺陷：纯向量检索漏 30–50% 相关文档；只做权限过滤≠检索质量。

环节	做法	指标/门禁
召回	BM25(关键词/专名)+向量，RRF/学习排序融合	Recall@100≥0.95
重排	Top-100 用 cross-encoder 重排至 Top-K	MRR/nDCG 提升
切分	语义切分+父子文档，保留来源/章节/权限元数据	片段可溯源
评测	≥200 条 golden queries + 标准 doc_id 集	CI 门禁阻断

- 两层过滤：检索阶段先保“找得全”（质量层），再在第18章单一过滤点做“看不见”（合规层），二者解耦。

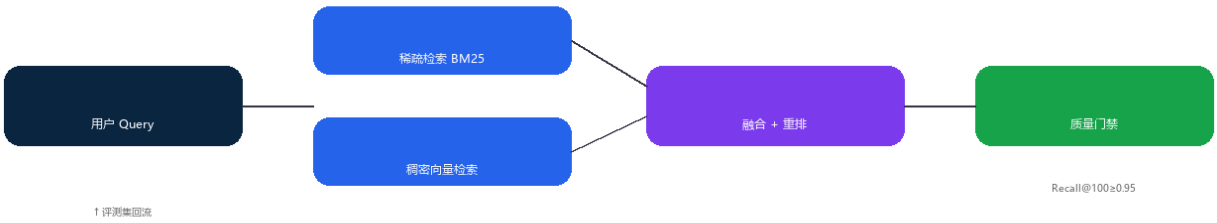


图 36.2 混合检索 + 重排 + 质量门禁

P0 37. ML 级评测体系

缺陷：评测依赖 LLM-as-judge，人机相关性仅 0.59–0.66 会一致错，演化飞轮地基不可靠。

- 客观指标用规则校验：格式/工具参数/检索命中/引用/越权拦截，不靠 LLM。
- 建 ≥500 条黄金集（多轮+边界）作回归基线，每次改动必跑。
- LLM-as-judge 仅辅助：多模型交叉+校准阈值，不单独定生死。
- 人工抽检+用户反馈回流第20章演化；演化建议须过评测门禁（黄金集不退化）才灰度。

P1 38. 非 LLM 模型 MLOps

缺陷：机器学习方案只有推理调用，缺训练/特征/版本/漂移/重训。

- 特征存储：离线+在线统一管理，训练-serving 一致。
- 训练流水线：清洗→特征→训练→评估→注册，可定时重跑。
- 模型注册表与版本：与第25章网关同表（adapter=ml_serving）。
- 漂移检测：PSI/KS 监控输入分布与效果衰减，超阈告警。
- 重训与回滚：漂移触发重训，灰度+旧版可回滚。

P1 39. 幻觉抑制与 Grounding

缺陷：第27章只列威胁无手段，企业最怕说错话。

- 引用强制：每段附可点击来源，无来源不得生成事实断言。
- 事实校验：生成后做声明-证据比对，证据不在检索集则标记/拒答。
- 置信校准与拒答：低置信/无支撑走拒答或转人工（第42章）。
- 输出合规校验层：生成后规则/小模型过滤敏感与越权。

P1

40. 成本与延迟优化

缺陷：第25章有计费无优化；无路由无语义缓存，规模上来成本失控。

- 任务路由器：简单→小模型，复杂→大模型，策略可配。
- 语义缓存：相似 Query 命中缓存（embedding 相似度阈值）。
- 模型分层与预算：注册表标 tier/单价，高成本单独审批，超预算熔断。
- 高频请求预计算，命中即返回。

P1 41. 模型质量可观测性

缺陷：第25章只记 token/成本，不记成功率/幻觉率/转人工率。

- 扩展计量埋点：成功率/幻觉率/转人工率/满意度/延迟 p95。
- 与第26章指标-日志-链路三支柱打通，按 tenant/dept/agent 下钻。
- 质量告警：幻觉率/转人工率突增自动告警触发演化复盘。
- 质量看板受 scope 约束，成本/质量仅管理员可见。

P2 42. 优雅降级与人工升级

缺陷：Agent 静默失败或硬报错，无置信阈值触发升级。

- 置信阈值：每答带置信分，低于阈值走降级链（小模型→规则→人工）。
- 降级链配置：每智能体可配降级顺序与兜底话术。
- 人工升级：转人工带完整上下文与置信理由，进工单/审批流。

P2 43. 中文语言特化

缺陷：Embedding/LLM 需中文优化未单列，分词专名易错。

- 默认中文 embedding（bge/bce 系列），第25章注册表可切。
- 检索切分考虑中文语义边界，避免标点粗暴切。
- 建中文少样本/系统 Prompt 模板库，规避翻译腔。
- 用 C-Eval/CMMLU/内部中文集做回归基准。

P2 44. Agent/工具层安全闭环

缺陷：第18章过滤点只在检索层；工具调用/外部API 可绕过权限外泄。

- 工具调用也过权限：每工具声明 scope/数据域，调用前校验 caller。
- 外部 API 沙箱与脱敏：去手机/身份证/密钥，仅白名单域名。
- 工具审计：入参/出参/调用者进统一审计流（第29章）。
- 复用第18章单一过滤点代码，不另起炉灶。